

Diffusion models

Chapter1

矢口 真那斗

2024 年 6 月 7 日

# 目次

第 1 章	生成モデル	2
1.1	生成モデルとは何か . . . . .	2
1.2	エネルギーベースモデル・分配関数 . . . . .	2
1.3	学習手法 . . . . .	3

## 第 1 章

# 生成モデル

### 1.1 生成モデルとは何か

生成モデルとは、変数  $\theta$  でパラメトライズされた確率分布  $q_\theta(\mathbf{x})$  であり、この分布に従ってサンプリングすることで、対象ドメインのデータを生成できるモデルである。

ここでは、生成モデルを訓練データから学習することを考える。訓練データは iid である  $N$  個のデータからなるデータセット  $D = \{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(N)}\}$  であり、未知の確率分布  $p(\mathbf{x})$  に従うとする。ただし、 $\mathbf{x}^{(i)} \in \mathbb{R}^d$  は  $d$  次元ベクトルである  $i$  番目のデータ、 $x_i \in \mathbb{R}$  は  $\mathbf{x}$  の  $i$  次元目の成分である。

生成モデルの学習の目標は、目標確率分布  $p(\mathbf{x})$  にできるだけ近い確率分布  $q_\theta(\mathbf{x})$  を見つけることである。

### 1.2 エネルギーベースモデル・分配関数

データ  $\mathbf{x} \in X$  に対して、エネルギー関数  $f(\mathbf{x}; \theta) : \mathbb{R}^d \rightarrow \mathbb{R}$  を導入する。また生成モデルの確率分布  $q_\theta(\mathbf{x})$  を、エネルギー関数を用いて次のように定義する。

$$q_\theta(\mathbf{x}) = \frac{\exp(-f_\theta(\mathbf{x}))}{Z(\theta)} \quad (1.1)$$

$$Z(\theta) = \int_{\mathbf{x}' \in X} \exp(-f_\theta(\mathbf{x}')) d\mathbf{x}' \quad (1.2)$$

ここで、 $Z(\theta)$  を分配関数とよぶ。このとき、エネルギー  $f_\theta(\mathbf{x})$  が小さいほど、データ  $\mathbf{x}$  が生成される確率が大きくなることを意味する。これは物理学におけるエネルギーの概念と対応しており、エネルギーベースモデルとよばれる。

エネルギーベースモデルの特徴として、構成性を挙げる。2 つのエネルギー関数、 $f_1(\mathbf{x}), f_2(\mathbf{x})$  と、対応する確率分布  $q_1(\mathbf{x}), q_2(\mathbf{x})$  を考える。このとき、エネルギー関

数の和  $f(\mathbf{x}) = f_1(\mathbf{x}) + f_2(\mathbf{x})$  に対応する確率分布  $q(\mathbf{x})$  は、次のようになる。

$$q(\mathbf{x}) \propto \exp(-f(\mathbf{x})) \quad (1.3)$$

$$= \exp(-f_1(\mathbf{x}) - f_2(\mathbf{x})) \quad (1.4)$$

$$= \exp(-f_1(\mathbf{x}))\exp(-f_2(\mathbf{x})) \quad (1.5)$$

$$= q_1(\mathbf{x})q_2(\mathbf{x}) \quad (1.6)$$

このように、エネルギー関数の和に対応する確率分布は、それぞれの確率分布の積になる。この性質は、生成モデルの構築において、複数のエネルギー関数を組み合わせる際に有用である。

## 1.3 学習手法

生成モデルの学習手法として、尤度ベースモデルとよばれる手法と、暗黙的生成モデルとよばれる手法の2つを紹介する。

### 1.3.1 尤度ベースモデル

あるデータ  $\mathbf{x}$  の生成確率  $q_\theta(\mathbf{x})$  を尤度とよぶ。訓練データセット  $D = \{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(N)}\}$  の尤度は、データが i.i.d であるから次のようになる。

$$q_\theta(D) = q_\theta(\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(N)}) = \prod_{i=1}^N q_\theta(\mathbf{x}^{(i)}) \quad (1.7)$$

対数尤度  $L(\theta)$  は、次のようになる。

$$L(\theta) = \log q_\theta(D) = \sum_{i=1}^N \log q_\theta(\mathbf{x}^{(i)}) \quad (1.8)$$

対数尤度を最大にするパラメータ  $\theta_{ML}^* := \arg \max_\theta L(\theta)$  を求めるのが、最尤推定である。

エネルギーベースモデルの場合の対数尤度を考える。  $q_\theta(\mathbf{x}) = \frac{\exp(-f_\theta(\mathbf{x}))}{Z(\theta)}$  より、対数尤度は次のようになる。

$$L(\theta) = \sum_{i=1}^N \log q_\theta(\mathbf{x}^{(i)}) \quad (1.9)$$

$$= \sum_{i=1}^N \log \frac{\exp(-f_\theta(\mathbf{x}^{(i)}))}{Z(\theta)} \quad (1.10)$$

$$= - \sum_{i=1}^N f_\theta(\mathbf{x}^{(i)}) - N \log Z(\theta) \quad (1.11)$$

$$= - \sum_{i=1}^N f_\theta(\mathbf{x}^{(i)}) - N \log \int_{\mathbf{x}' \in X} \exp(-f_\theta(\mathbf{x}')) d\mathbf{x}' \quad (1.12)$$

式 (1.12) より、対数尤度を最大にすることは、訓練データの位置のエネルギーを小さくし (第一項)、一方ですべての位置のエネルギーを大きくすることに対応する (第二項)。

” $f_\theta(\mathbf{x}) = \exp(g_\theta(\mathbf{x}))$  と表せる場合を考えてみたい, 鋭くなる、記憶容量大、汎化性低?”

対数尤度を最大化するために、勾配法を用いることを考える。

$$\frac{\partial L(\theta)}{\partial \theta} = - \sum_{i=1}^N \frac{\partial f_\theta(\mathbf{x}^{(i)})}{\partial \theta} - N \frac{\partial}{\partial \theta} \log Z(\theta) \quad (1.13)$$

$$= - \sum_{i=1}^N \frac{\partial f_\theta(\mathbf{x}^{(i)})}{\partial \theta} - N \frac{1}{Z(\theta)} \int_{\mathbf{x}' \in X} -\exp(-f_\theta(\mathbf{x}')) \frac{\partial f_\theta(\mathbf{x}')}{\partial \theta} d\mathbf{x}' \quad (1.14)$$

$$= - \sum_{i=1}^N \frac{\partial f_\theta(\mathbf{x}^{(i)})}{\partial \theta} + N \int_{\mathbf{x}' \in X} q_\theta(\mathbf{x}) \frac{\partial f_\theta(\mathbf{x}')}{\partial \theta} d\mathbf{x}' \quad (1.15)$$

$$= - \sum_{i=1}^N \frac{\partial f_\theta(\mathbf{x}^{(i)})}{\partial \theta} + N \mathbb{E}_{\mathbf{x} \sim q_\theta(\mathbf{x})} \left[ \frac{\partial f_\theta(\mathbf{x})}{\partial \theta} \right] \quad (1.16)$$

ここで第二項は、生成モデルの確率分布に関して期待値を取ったものである。これをシュミレーションで求める際は、モンテカルロサンプリングを行うことが一般的であるが、計算コストが大きい。